Apoio à triagem de lesões de pele com redes neurais

Relatório do Projeto Final InsperAI

Felipe Gava e Lucas Briones · novembro de 2026

Natureza do trabalho. Projeto acadêmico de apoio à triagem. Os resultados são sugestões ou orientações, nunca diagnósticos, e não substituem a avaliação de um profissional de saúde. As orientações de urgência são um rascunho que ainda precisa ser revisado por um profissional de saúde.

Resumo

O trabalho tem duas partes. A **Parte 1** é um classificador de lesões em imagens dermatoscópicas, treinado com 25.331 imagens do ISIC 2019 (HAM10000, BCN_20000 e MSK). No teste do ISIC 2018, ele alcança **82,2% de acurácia**, **74,3% de acurácia balanceada** e **95,8% de sensibilidade** na triagem de malignidade, acima da média de dermatologistas sem apoio de IA nas mesmas imagens (71,4%).

A **Parte 2** amplia o sistema para erupções, alergias e infecções em fotos de celular, usando o SCIN (Google) e o PAD-UFES-20. O detector de tipo de foto funciona bem (98,6%). O restante mostra os limites do que dá para fazer com estes dados. O especialista em erupções acerta a condição na primeira sugestão em 28% das imagens e entre as três primeiras em 69%. O roteador acerta 96,8% dentro das bases, mas reconhece só 5,7% das pintas do SCIN num teste externo, sinal de que aprendeu a origem das fotos. O erro mais grave, orientar cuidados em casa quando o caso precisaria de atendimento, ocorre em **12,2%** dos casos que precisariam de atendimento (**31,8%** nas fotos do SCIN). **A conclusão é que o sistema é promissor em dermatoscopia, mas ainda não está pronto para orientar pessoas a partir de fotos caseiras.**

1. Objetivo e contexto

O câncer de pele é o tipo de câncer mais comum, e o melanoma é o mais letal; o diagnóstico cedo muda muito o prognóstico. O exame de rotina é a dermatoscopia, cuja interpretação exige experiência. O diagnóstico definitivo vem da biópsia.

O objetivo foi construir modelos que, a partir de uma imagem, sugiram o tipo da lesão e o próximo passo, como apoio à decisão num consultório. A estratégia inicial é professor-aluno: um modelo "professor" busca a máxima acurácia e, em etapa futura, um modelo menor ("aluno") aprende a imitá-lo por destilação de conhecimento.

Como a base é desbalanceada, com cerca de metade das imagens de nevos benignos, a métrica principal é a **acurácia balanceada**, média da sensibilidade de cada classe e métrica oficial do desafio ISIC.

2. Bases de dados

Base	Papel	Imagens	Tipo de foto	Observações
ISIC 2019 (HAM10000, BCN_20000, MSK)	Treino e validação da Parte 1	25.331	Dermatoscopia	8 classes; validação de 15% sorteada por lesão
ISIC 2018 Task 3	Teste da Parte 1	1.511	Dermatoscopia	7 classes; akiec junta ak e scc
ISIC 2019 (teste, sem rótulo)	Reservada para o aluno	6.726	Dermatoscopia	Sem rótulos
SCIN (Google)	Erupções e alergias (Parte 2)	9.998 (5.434 após limpeza)	Celular	25 de 26 arquivos; rótulos com pesos, de dermatologistas
PAD-UFES-20	Pintas em foto de celular (Parte 2)	2.283	Celular	Divisão por paciente

3. Parte 1: classificador de lesões em dermatoscopia

Preparação das imagens

- **Unificação** das fontes num único conjunto, com divisão por lesão, para que fotos da mesma lesão nunca fiquem em conjuntos diferentes.
- **Constância de cor Shades of Gray**, para uniformizar a cor entre dermatoscópios.
- **Data augmentation** no treino: recortes (50% a 100% da área), espelhamentos, rotações de 90°, variação de cor e uma borda circular artificial em 25% das imagens, para evitar que a rede use a borda preta das imagens do BCN como atalho.

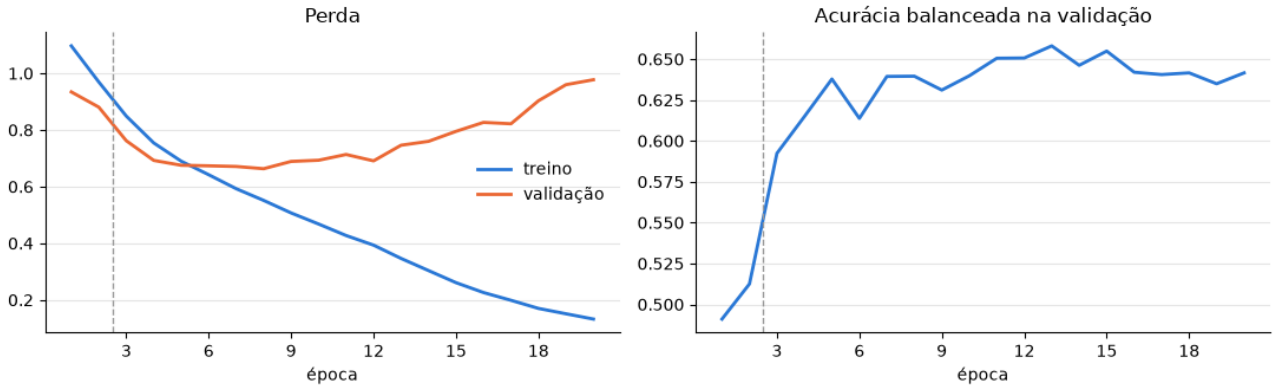
Modelo e treino

O professor local é uma **EfficientNetV2-B0** pré-treinada no ImageNet, com 224 px e idade, sexo e região do corpo como segunda entrada. O PC não tem GPU, por isso a rede é pequena; uma versão maior para GPU (EfficientNetV2-S, 384 px, com ensemble) está pronta em *kaggle_professor.ipynb*.

- **Fase 1:** só a cabeça, com a rede congelada (baseline de embeddings, 2 épocas).
- **Fase 2:** ajuste fino da rede inteira, com BatchNormalization congeladas, AdamW, aquecimento e decaimento cosseno, até 20 épocas com parada antecipada.

- **Desbalanceamento:** entropia cruzada comum e ajuste de logits pelo prior do treino, com intensidade escolhida na validação.
- **Previsão:** média de 8 versões de cada imagem (TTA, 4 rotações × espelhamento).

A rede foi treinada em cerca de 7 horas na CPU. Duas interrupções por falta de memória foram contornadas com backups por época e BatchNormalization congeladas, o que reduziu o pico de memória de 3,9 GB para 2,7 GB.



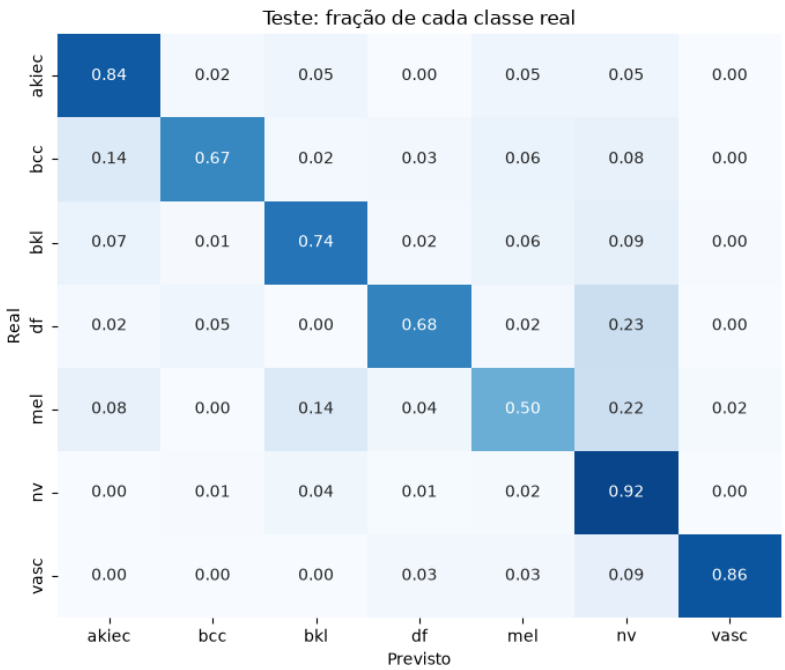
Curvas de treino. A linha tracejada separa as fases. A perda de validação sobe a partir da 8ª época enquanto a de treino cai: há overfitting, e por isso se guarda a melhor época.

Resultados no teste (ISIC 2018, 1.511 imagens)

Variante	Acurácia	Acurácia balanceada	AUC maligno × benigno
Fase 1: rede congelada (baseline)	67,1%	47,7%	0,867
Fase 2: ajuste fino	81,8%	72,4%	0,938
Fase 2 + TTA (final)	**82,2%**	**74,3%**	**0,943**

Comparação nas mesmas 1.412 imagens (Tschandl et al., 2020)	Acurácia	Acurácia balanceada
Dermatologistas sem IA	69,4%	71,4%
Nosso professor	**76,7%**	**74,1%**
Dermatologistas com a IA do estudo	74,4%	75,4%
IA do estudo	78,2%	77,7%

Triagem maligno × benigno: com limiar escolhido na validação para 95% de sensibilidade, o teste teve 95,8% de sensibilidade e 73,3% de especificidade.



Matriz de confusão no teste (fração de cada classe real). O melanoma é o ponto fraco: só 50% de acerto como classe exata, e 22% saem como nevo.

4. Parte 2: triagem em duas etapas

Exploração do SCIN

- 61% dos casos têm rótulo de dermatologista, e os rótulos são incertos: só 665 casos têm condição única, e o peso mediano da condição principal é 0,55.
- Cauda longa: 205 condições como principal, das quais só 20 têm pelo menos 30 casos.
- Queimaduras e feridas são raras (4 e 30 casos após a limpeza). Pintas também (17 casos).
- Predominam tons claros de pele, e Fitzpatrick falta em 50% dos casos.

Limpeza

Etapa	Imagens removidas	Imagens restantes	Casos restantes
Entrada		9.998	4.839
Corrompidas	0	9.998	4.839
Muito pequenas (< 224 px)	26	9.972	4.838
Duplicatas exatas (MD5)	25	9.947	4.820
Quase-duplicatas	15	9.932	4.818
Duplicatas com as bases de pintas	0	9.932	4.818
Não avaliáveis	3.782	6.150	2.942
Sem rótulo	175	5.975	2.847
Confiança muito baixa	541	**5.434**	**2.581**

Na revisão manual de pares, o pHash sozinho marcava como iguais fotos de pessoas diferentes, porque fotos de pele têm pouco detalhe. Por isso o critério final combina pHash (candidatas) e correlação de pixels ≥ 0,98 (confirmação). As 145 condições com menos de 30 casos foram agrupadas em "outras

condições". A divisão 70/15/15 é por caso, com verificação por código de que não há vazamento.

Arquitetura

Etapa	Entrada	Saída
Detector de tipo de foto	Qualquer imagem	Dermatoscopia → modelo de pintas (Parte 1); celular → roteador
Roteador	Foto de celular	Pinta → orientação de avaliação médica; erupção/alergia → especialista; baixa confiança → "não foi possível identificar"
Especialista	Erupção ou alergia	3 condições mais prováveis entre 17 classes
Regras (orientacoes.yaml)	Condição e perguntas de alerta	Urgência e orientação de texto fixo

O plano inicial era um roteador único juntando as bases de pintas e o SCIN. Como isso ensinaria a rede a separar câmeras, adotamos dois passos: primeiro o tipo de foto, depois o roteador só com fotos de celular. Pintas em foto de celular não passam pelo modelo de pintas, que só conhece dermatoscopia. Grupos de queimaduras e feridas ficam previstos, mas desativados.

Todas as redes usam EfficientNetV2-B0, 224 px, duas fases de treino, peso por classe (raiz do inverso da frequência) e variação de cor moderada, porque a cor é informação diagnóstica. Calibração por temperatura e limiar de baixa confiança foram ajustados só na validação. O especialista foi treinado com rótulo único e com rótulos suaves; a validação escolheu os **rótulos suaves** (F1 macro de 25,3% contra 23,1%).

Orientação de próximo passo

A orientação vem só de um arquivo de regras, nunca de texto gerado pelo modelo. Cada condição tem um nível: **Emergência** (pronto-socorro ou SAMU 192), **Consulta em breve** ou **Cuidados em casa**. As perguntas de alerta (como falta de ar, inchaço no rosto, febre, pus, diabetes) elevam a urgência independentemente do modelo. Baixa confiança resulta em "não foi possível identificar; procure avaliação médica".

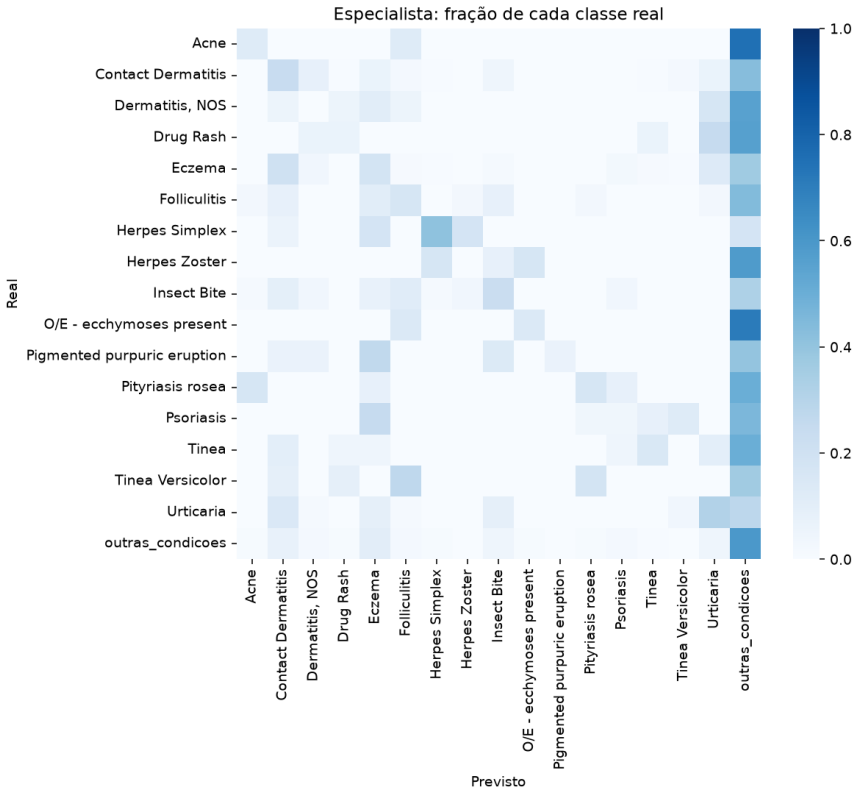
5. Resultados da triagem no teste

Componente	Métrica	Valor
Detector de tipo de foto	Acurácia balanceada	98,6%
Roteador	Acurácia balanceada (dentro das bases)	96,8%
Roteador	Pintas do SCIN reconhecidas (teste externo, 35 imagens)	**5,7%**
Especialista (17 classes)	Acerto na 1ª sugestão / entre as 3 primeiras	28,3% / 69,2%
Especialista	Acurácia balanceada / F1 macro	17,0% / 18,2%
Especialista	AUROC macro	0,81
Especialista	Erro de calibração (antes → depois)	0,165 → 0,058

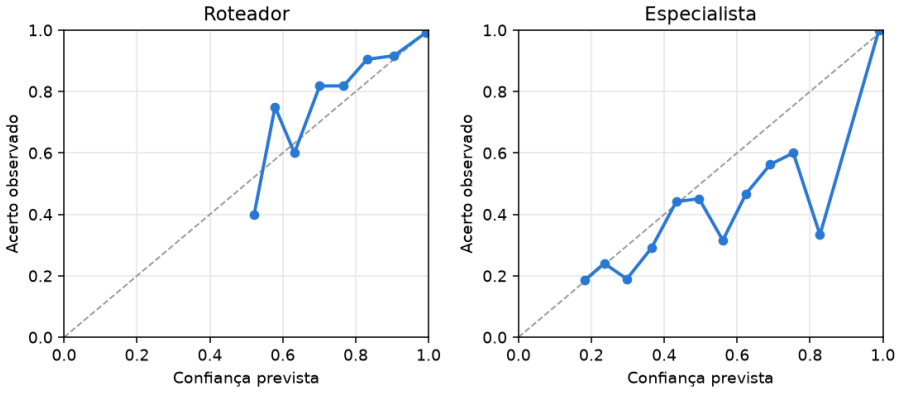
Erro grave: orientar cuidados em casa quando precisaria de atendimento

Origem	Imagens	Precisavam de atendimento	Erros graves	Taxa
Geral	2.671	868	106	**12,2%**
Dermatoscopia (ISIC)	1.511	307	13	**4,2%**
PAD-UFES	344	272	1	**0,4%**
SCIN	816	289	92	**31,8%**

A taxa sobe bastante nas fotos do SCIN: condições que exigiriam consulta são confundidas com outras de cuidados em casa. A medida não considera as perguntas de alerta, que elevariam a urgência em parte dos casos, e parte de rótulos incertos.



Especialista: matriz de confusão no teste. Boa parte dos erros cai em "outras condições".

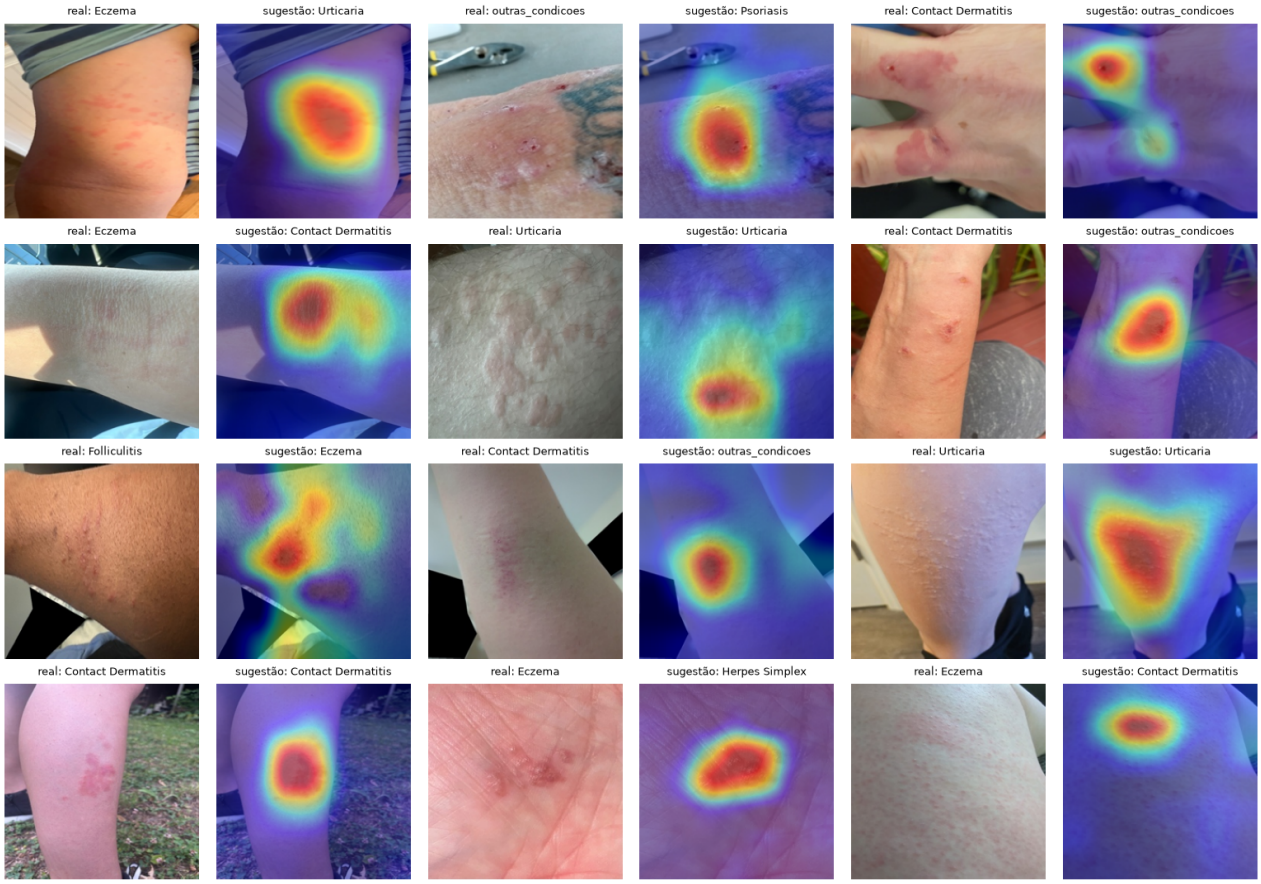


Diagramas de confiabilidade, depois do ajuste de temperatura. O roteador acompanha a diagonal; o especialista fica abaixo dela em boa parte da faixa, ou seja, ainda superestima a própria confiança.

Tipo de pele

Monk	Imagens	Casos	Acurácia balanceada do especialista	Erro grave
1-2	381	178	17,7%	27,9%
3-4	314	151	17,2%	42,6%
5-6	83	40	15,4%	24,3%
7-10	20	9	73,3%	13,3%

Não há diferença clara nos grupos com dados suficientes, mas as amostras são pequenas: Monk 7 a 10 tem só 9 casos, e o valor ali não tem significância. Não dá para afirmar que o sistema é justo entre tons de pele.



Grad-CAM do especialista: na maior parte, a atenção cai sobre a pele afetada, e não sobre o fundo ou roupas. A amostra é pequena e os mapas tendem ao centro.

6. Limitações

- **Roteador confundido pela origem:** aprendeu mais a diferença entre PAD-UFES e SCIN do que entre pinta e erupção.
- **Especialista fraco:** poucos casos por classe, rótulos incertos, fotos caseiras e rede pequena, treinada em CPU.
- **Sem queimaduras e feridas:** dados insuficientes; os grupos estão desativados.
- **Conjunto incompleto:** falta um dos 26 arquivos do SCIN (cerca de 4% da base).
- **Pouca representatividade:** tons de pele escuros e pacientes idosos são raros.
- **Orientações:** ainda são um rascunho, a ser revisado por um profissional de saúde.
- **Modelo de pintas sem GPU:** resolução de 224 px e melanoma com só 50% de acerto como classe exata.

7. Próximos passos

- Reduzir o erro grave: somar a probabilidade das condições que pedem consulta e escolher um limiar de alta sensibilidade na validação, medindo em um teste novo.
- Obter fotos caseiras de pintas de outras fontes, para o roteador aprender lesão e não origem.
- Buscar bases específicas de queimaduras e feridas.
- Treinar na GPU do Kaggle, com redes maiores e maior resolução; o notebook já está pronto.
- Treinar o modelo aluno por destilação de conhecimento.
- Fazer revisar as orientações por um profissional de saúde.

8. Como reproduzir

Todo o trabalho está em **notebook.ipynb**, com código e texto: a Parte 1 e a Parte 2. As bases ficam fora do repositório, e os passos para prepará-las estão no README. As redes treinadas vêm em *modelos/*, de forma que o notebook pula os treinos e vai direto aos testes. A função *triagem(imagem, respostas_alerta)* devolve o grupo, as três condições mais prováveis, o nível de urgência e a orientação.